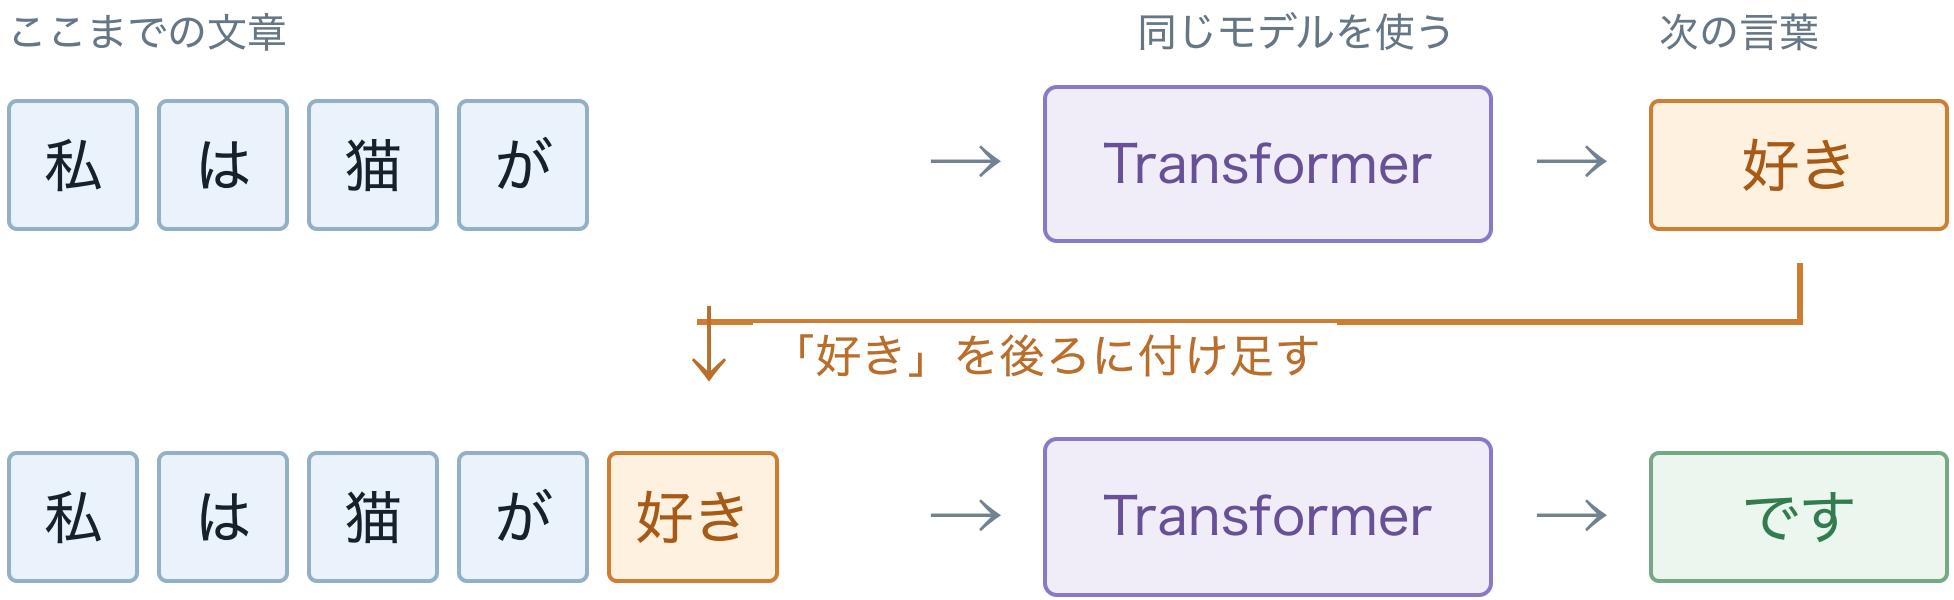
文章は、次の1個ずつ作る

出した言葉を入力に戻し、同じモデルで続きを予測します。



この繰り返しを **自己回帰** と呼びます。

本編9ページの補足。言葉の区切り・出力は説明用の例。実際は「トークン」という単位で予測。

文字だけの世界で考える

英字26文字と空白なら、候補は27種類です。

a	b	c	d	e	f	g	h	i
j	k	l	m	n	o	p	q	r
s	t	u	v	w	x	y	z	空白

27

種類から
次の1文字を選ぶ

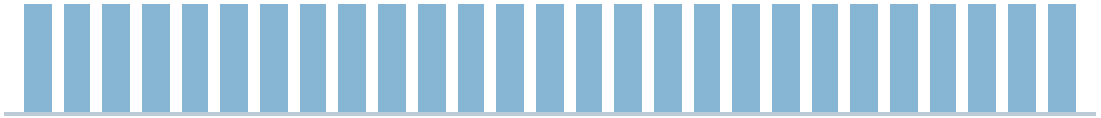
```
hel → hell → hello
```

ここでは説明を単純にするため、小文字26文字と空白だけを使う。

同じ27択でも、確率は変えられる

「hel」の続きなら、「l」などを選びやすくします。

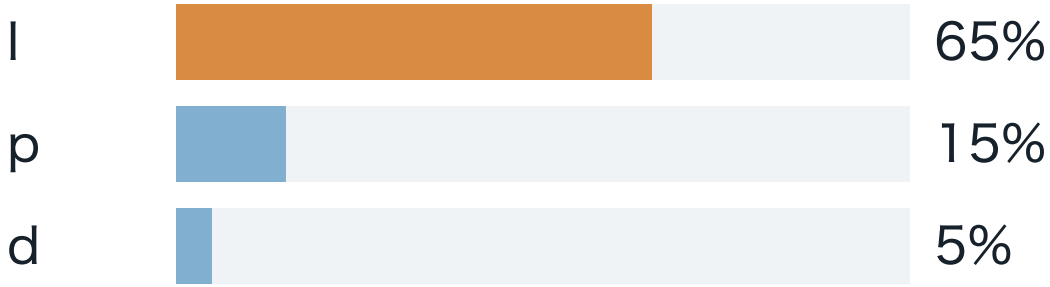
手がかりを使わない



27種類すべて 1/27

棒1本が、1種類の文字

「hel」を手がかりにする



残り24種類の合計：15%

hello / help / held などの続き

候補の数は同じ。変わるのは、**候補ごとの確率**。

確率は説明用の仮の数値。図の文字列は、出力を保証するものではない。

1948年：英語に似た文字列を作る

シャノンは、文字の頻度やつながりを使って、英語に似た文字列を作りました。

Claude E. Shannon　E = Elwood

以下は仕組みを示す自作の図（原論文の出力ではありません）。

同じ確率で選ぶ	A Q Z 空白 X J	どの文字も同じ出やすさ
文字の頻度を使う	E T A O E N	よく出る文字を選びやすく
前の文字も使う	Q → U	文字のつながりを使う

図は自作の説明例。原典：Shannon（1948）§3 ／ 氏名：MIT公式略歴

1951年：次の文字を、人に当ててもらう

シャノンは、英語の続きを人に予測させ、1文字あたりの情報量を推定しました。

以下は考え方を伝える自作例（原論文の実験問題ではありません）。

手がかりなし　　?

前の文字が見える　　HAPP ?　　Y？

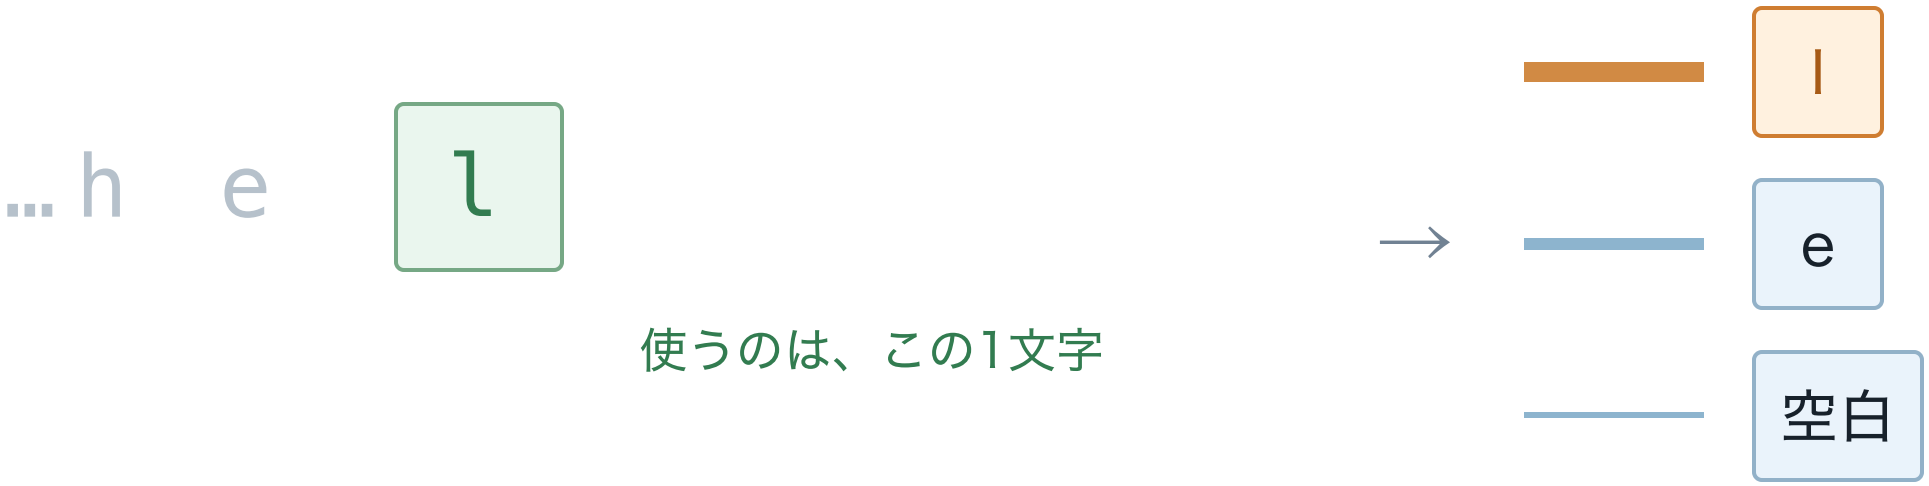
前の言葉も見える　　HAPPY BIRTHDA ?　　Y！

前の文章 ——— 次の文字を考える材料

図は自作例。1951年の研究は人による予測実験。原典：Prediction and Entropy of Printed English, §3

直前の1文字だけを見る方法

直前の1文字だけで次の確率を決めると、単純なマルコフ連鎖になります。

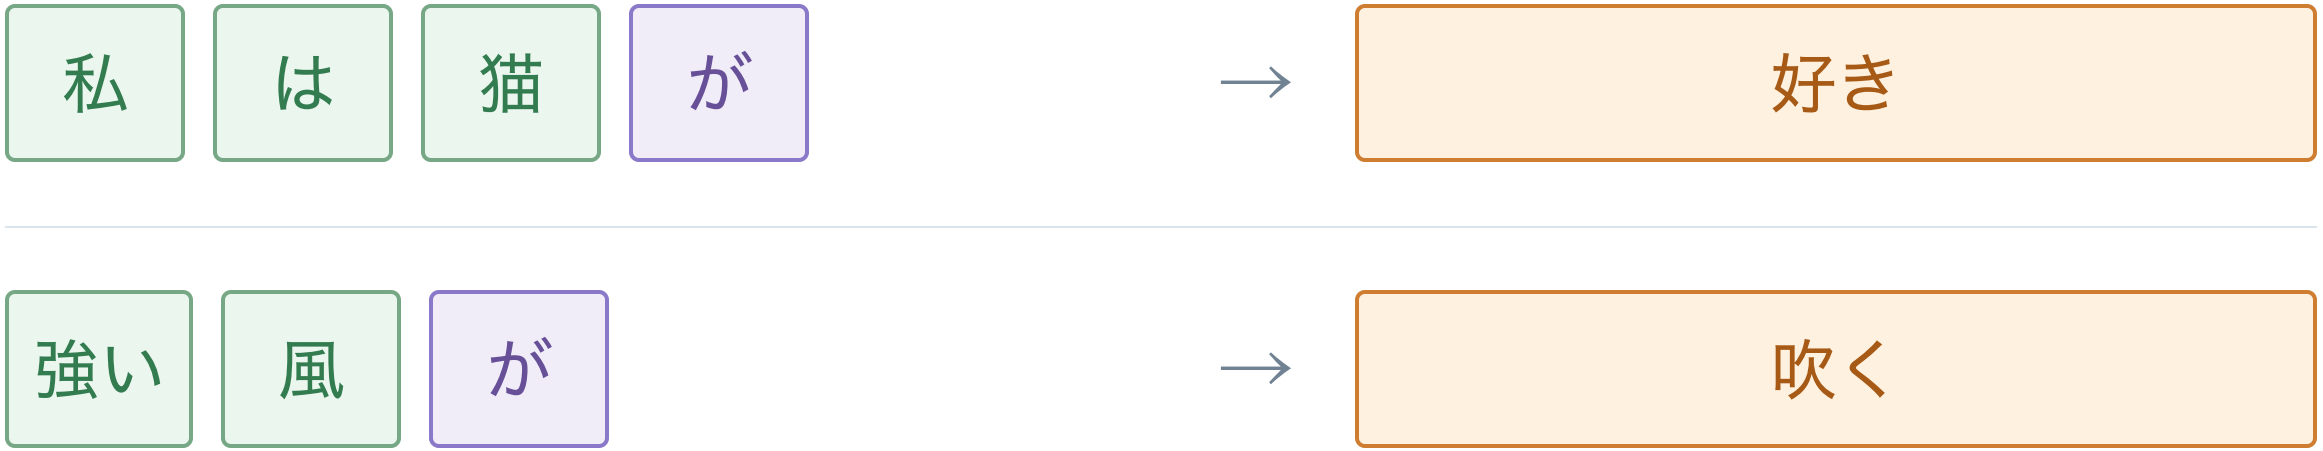


この例では、「l」より前の文字は使いません。

「状態＝直前の1文字」とした一階マルコフ連鎖の例。文字の頻度・枝の太さは模式図。

最後の文字が同じでも、続きは変わる

もっと前の言葉も使うと、続きを考える材料が増えます。



最後はどちらも「が」。**その前の話**が、次の予測に役立ちます。

文脈は「ここまでの文章」。区切りと続きは、理解のための説明例。

学習は、続きを当てる練習

実際の続きを見て、その言葉の確率を高くするように調整します。

hel
途中までを見せる

→ 予測するモデル →

l：20%
モデルの予測

教材の正解 l と比べて、モデルの中の数字を調整

調整する前

l 20%

→

調整を重ねた後

l 65%

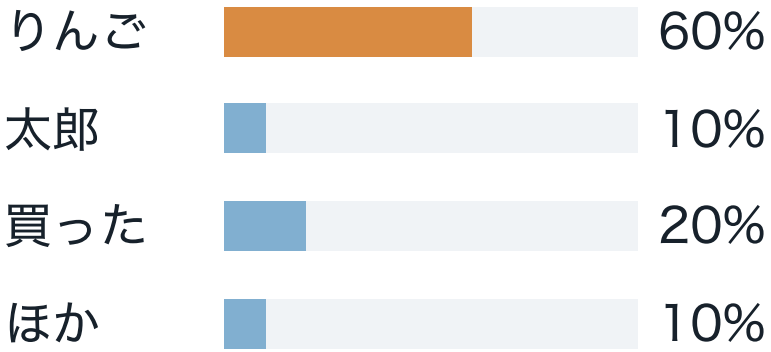
たくさんの文章で、この練習を繰り返します。

20%・65%は学習の方向を示す仮の数値。ほかの候補の棒は省略。学習の実装：scripts/model/boku_nano.py

Attentionは、前の情報を取り込む

どの位置の情報を、どのくらい取り込むかを計算します。

太郎	は	りんご	を	買った	。	それ



→

「それ」の情報に混ぜる

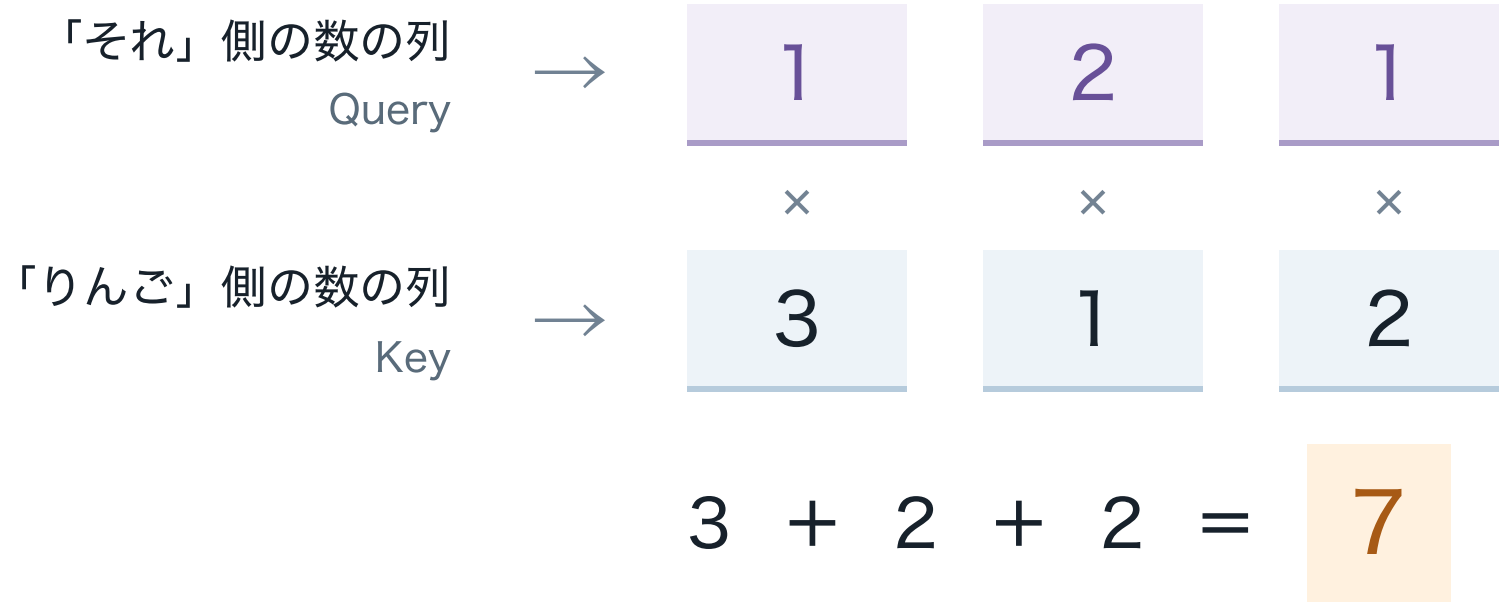
「りんご」の情報を多めに
ほかの位置の情報も取り込む

この処理を使って、続きを予測する。

重みは説明用。実測ではなく、次の言葉を選ぶ確率とも別。原典：Transformer（2017）§3.2

関係の点数は、掛け算と足し算で出す

言葉を数の列で表して、対応する数を掛け、合計します。

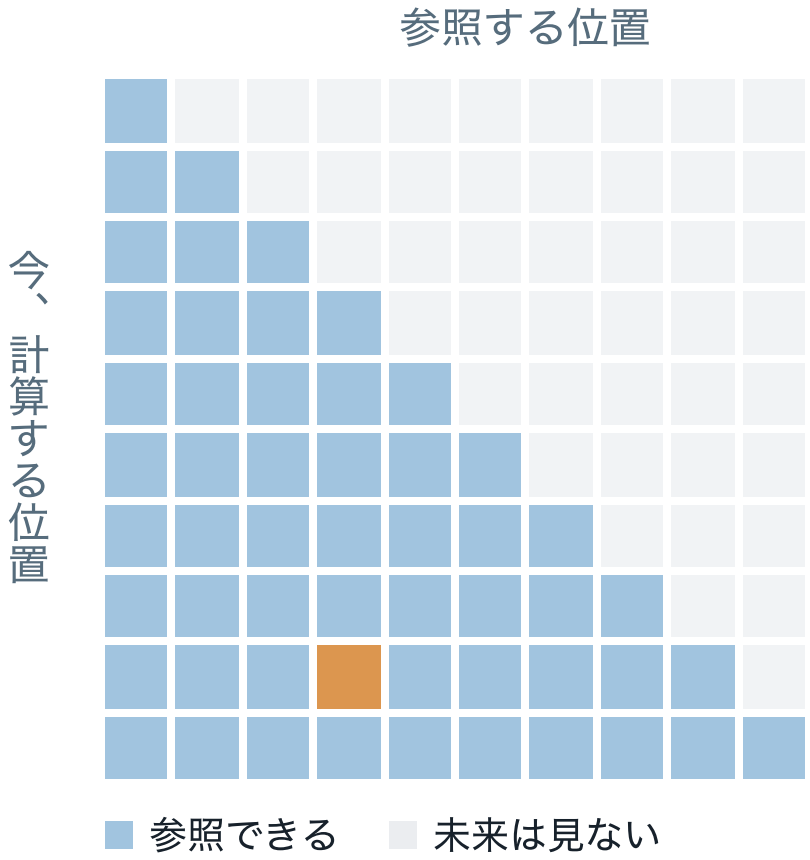


1組の関係を表す「点数」

3個の数は説明用の仮値。実際は点数の調整などをしてから重みに変換。原典：§3.2

文章が長いほど、調べる組が増える

入力文をまとめて処理するとき、各位置と各位置の関係を計算します。



1万 × 1万

表全体で 1億 マス

未来を除く有効な組は約5,000万。
各マスで、掛け算・足し算。

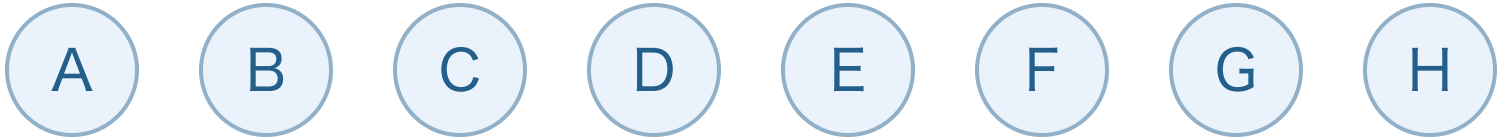
図は小さくした模式図。
1万個は規模を示す仮の設定。

学習・長い入力文をまとめて処理する場面。生成の各回に表全体を作り直すという意味ではない。原典 §4

8人の勝ち抜き戦を、1試合ずつ

1会場で7試合を順番に行うと、7分かかります。

8人から最強を1人決める。1試合1分、強い人が必ず勝つ。



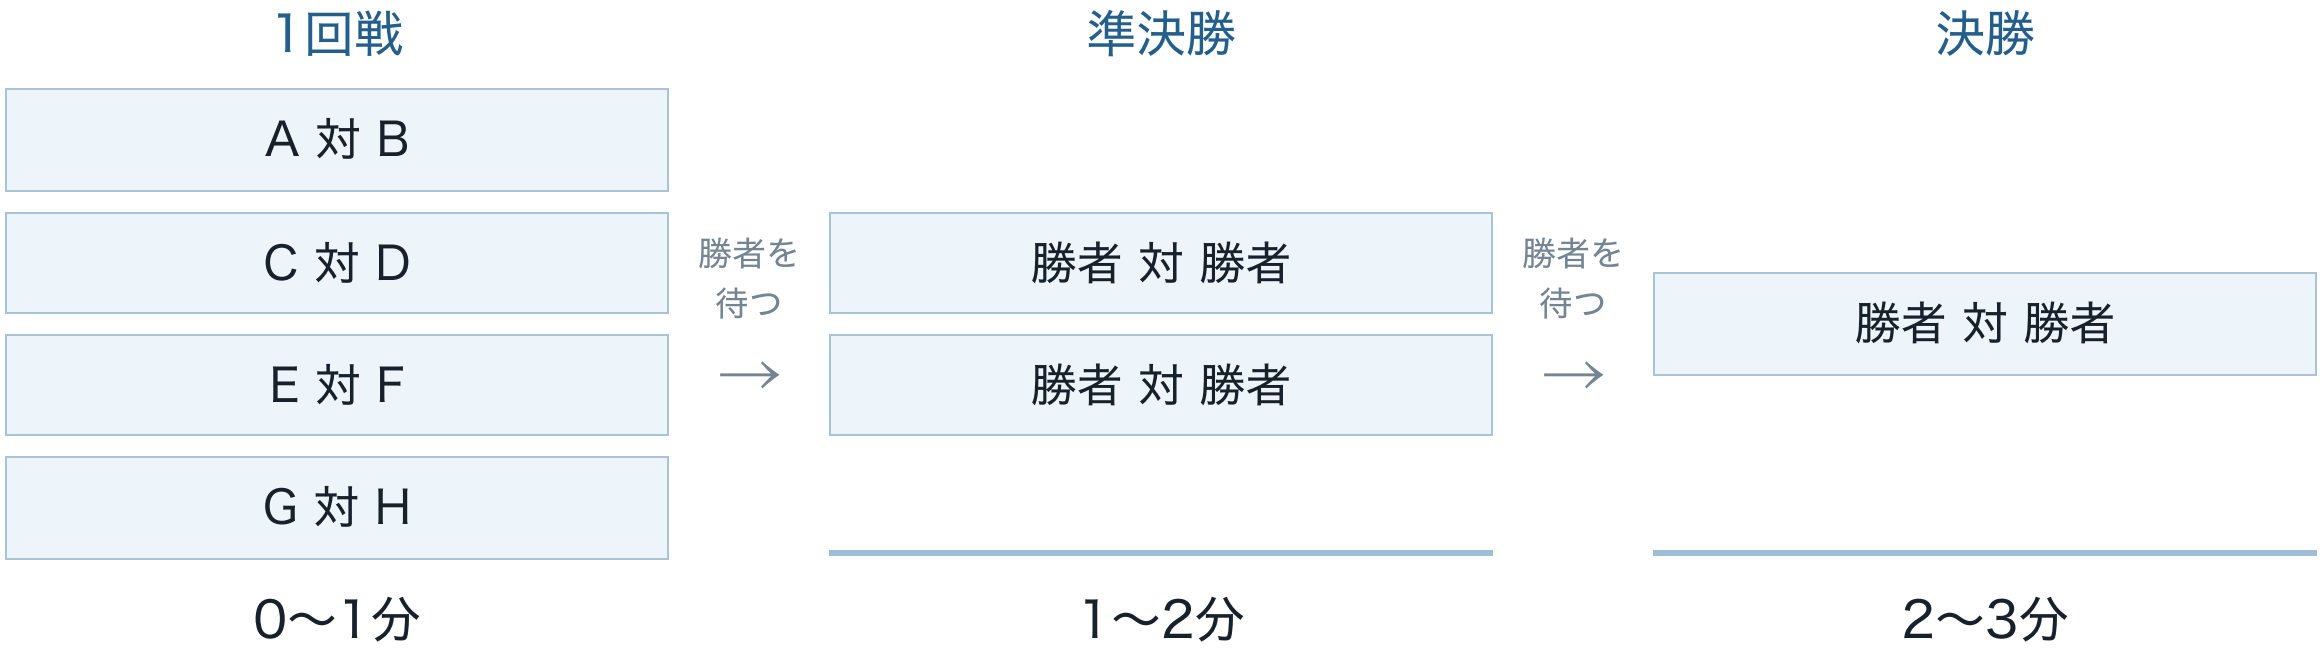
試合1	試合2	試合3	試合4	試合5	試合6	試合7
0〜1分	1〜2分	2〜3分	3〜4分	4〜5分	5〜6分	6〜7分

7試合 × 1分 **7分**

計算のたとえ。準備・移動時間は省略。CPUにも複数の仕事を同時に進める機能がある。

会場を増やして、同時に進める

同じラウンドを同時に行えば、7試合でも3分で終わります。



4試合 ＋ 2試合 ＋ 1試合 ＝ 7試合

経過時間 **3分**

1試合1分、強さは固定。各ラウンドの試合を同時に開催できるとした例。

クローンがいれば、総当たりも一斉に

全員が7試合へ同時参加できれば、28試合を1分で行えます。

A

Aも7か所で
同時に対戦

→

ほかの選手も同様

A 対 B	A 対 C	A 対 D	A 対 E	A 対 F	A 対 G	A 対 H
B 対 C	B 対 D	B 対 E	B 対 F	B 対 G	B 対 H	C 対 D
C 対 E	C 対 F	C 対 G	C 対 H	D 対 E	D 対 F	D 対 G
D 対 H	E 対 F	E 対 G	E 対 H	F 対 G	F 対 H	G 対 H

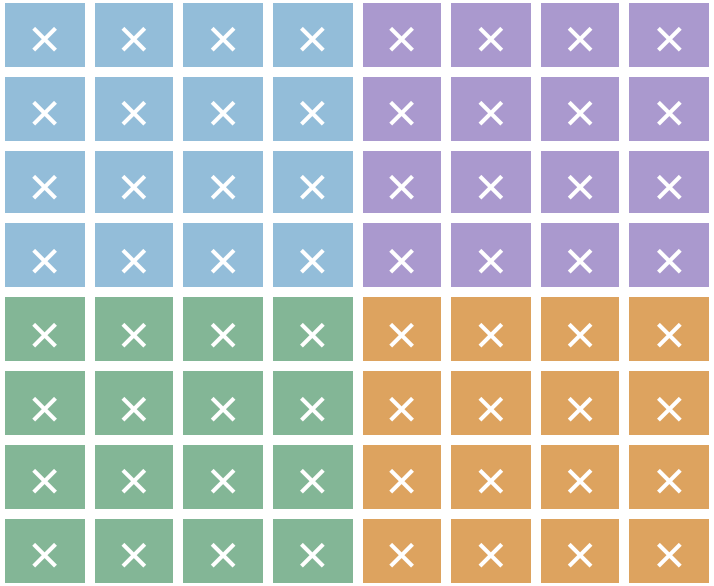
28会場で同時に **試合は1分** → 結果を集計

仕事の数が増えても、**同時にできれば待ち時間は短くなる。**

強さは固定。クローン・28会場を使える理想化した例。準備時間は省略し、集計時間は別。

GPUは、計算をたくさんの担当に分ける

同時にできる掛け算・足し算を、まとめて進めます。



大きな計算を、小さく分担

→

担当1	担当2	担当3	担当4
掛ける	掛ける	掛ける	掛ける
足す	足す	足す	足す
繰り返す	繰り返す	繰り返す	繰り返す

複数の担当が、同時に計算する

Transformerの中にある、大量の**行列の計算**と相性がよい。

4担当は仕組みを示す模式図。担当数やデータを運ぶ速度には上限がある。NVIDIA：行列積のGPU実装

CPUは、処理の流れを素早く進める

CPUは、制御と高速メモリを使い、1つの処理の流れを素早く進めます。

CPU

コア1	コア2
コア3	コア4

コア＝処理を進める担当

中を見る →

1つのコアの中（模式図）

制御・分岐予測
命令の流れを扱い、次の命令を準備

演算器
数を比べる
足す・掛ける

↔

キャッシュ
近くにある高速メモリ
データをすぐ使う

結果を見て処理を切り替えながら、**1つの流れの待ち時間を減らす**。

数・配置は模式図。CPUも並列処理をし、GPUにも制御やキャッシュがある。NVIDIA：CPUとGPUの設計の違い

小さなトーナメントは、CPUが有利なことも

少人数の比較なら、CPUでそのまま進める方が速い場合があります。

条件：8人の強さを表す数値がCPU側にあり、最強を1回だけ探す。

CPU

手元のデータを7回比較
勝者を次の比較へ進める
→ 最強が決まる

GPU

準備・必要な転送 → 比較を並列に行う → 結果を受け取る

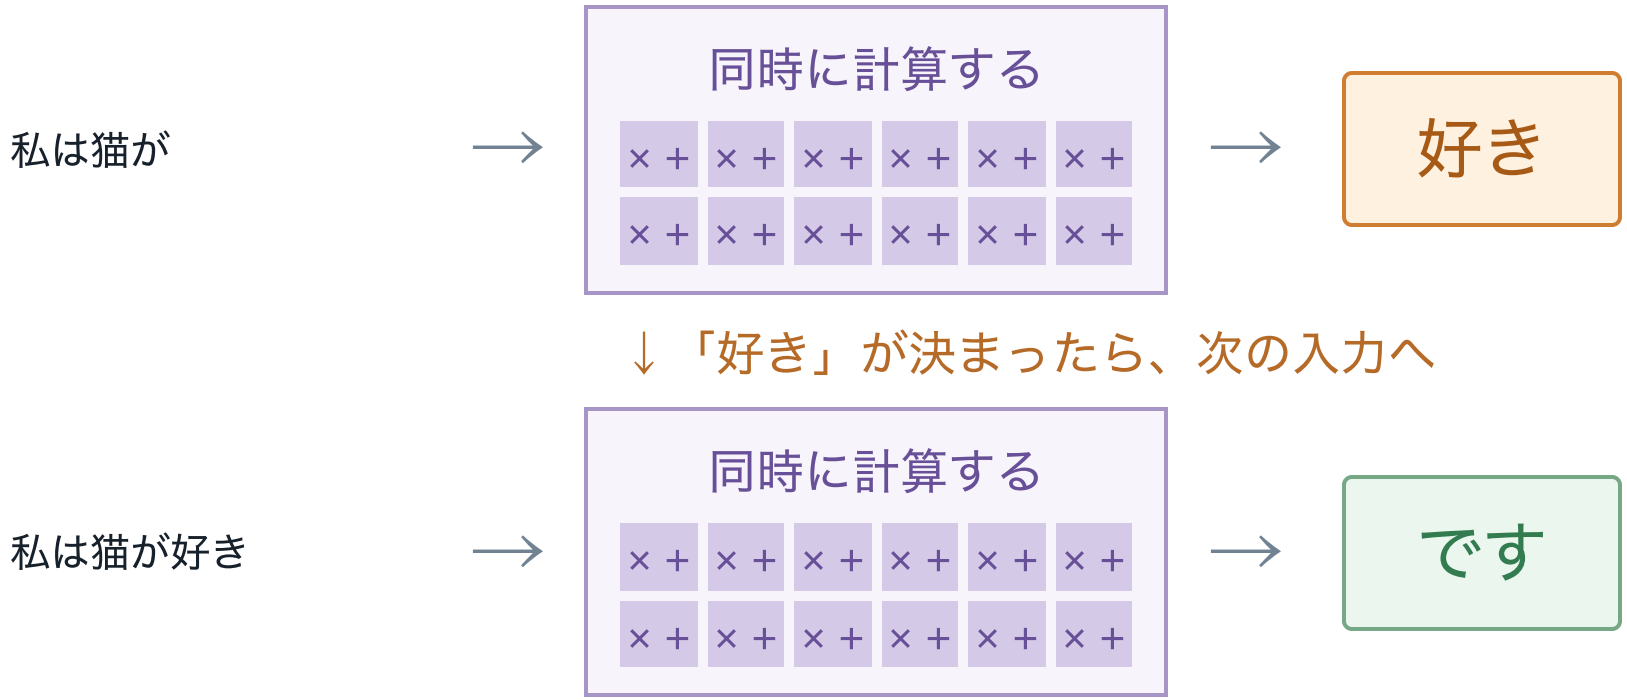
小さい仕事では、GPUへ依頼する準備の方が目立つことがある。

大量の比較なら、GPUが得意な並列処理を生かしやすい。

速度は規模・実装・データの置き場所で変わる。GPUも勝ち抜き型の比較を並列に行える。NVIDIA：GPUで実行する仕事の選び方

言葉を出す順番は、残る

GPUは1個を決める計算を速くし、通常の生成は1個ずつ進みます。



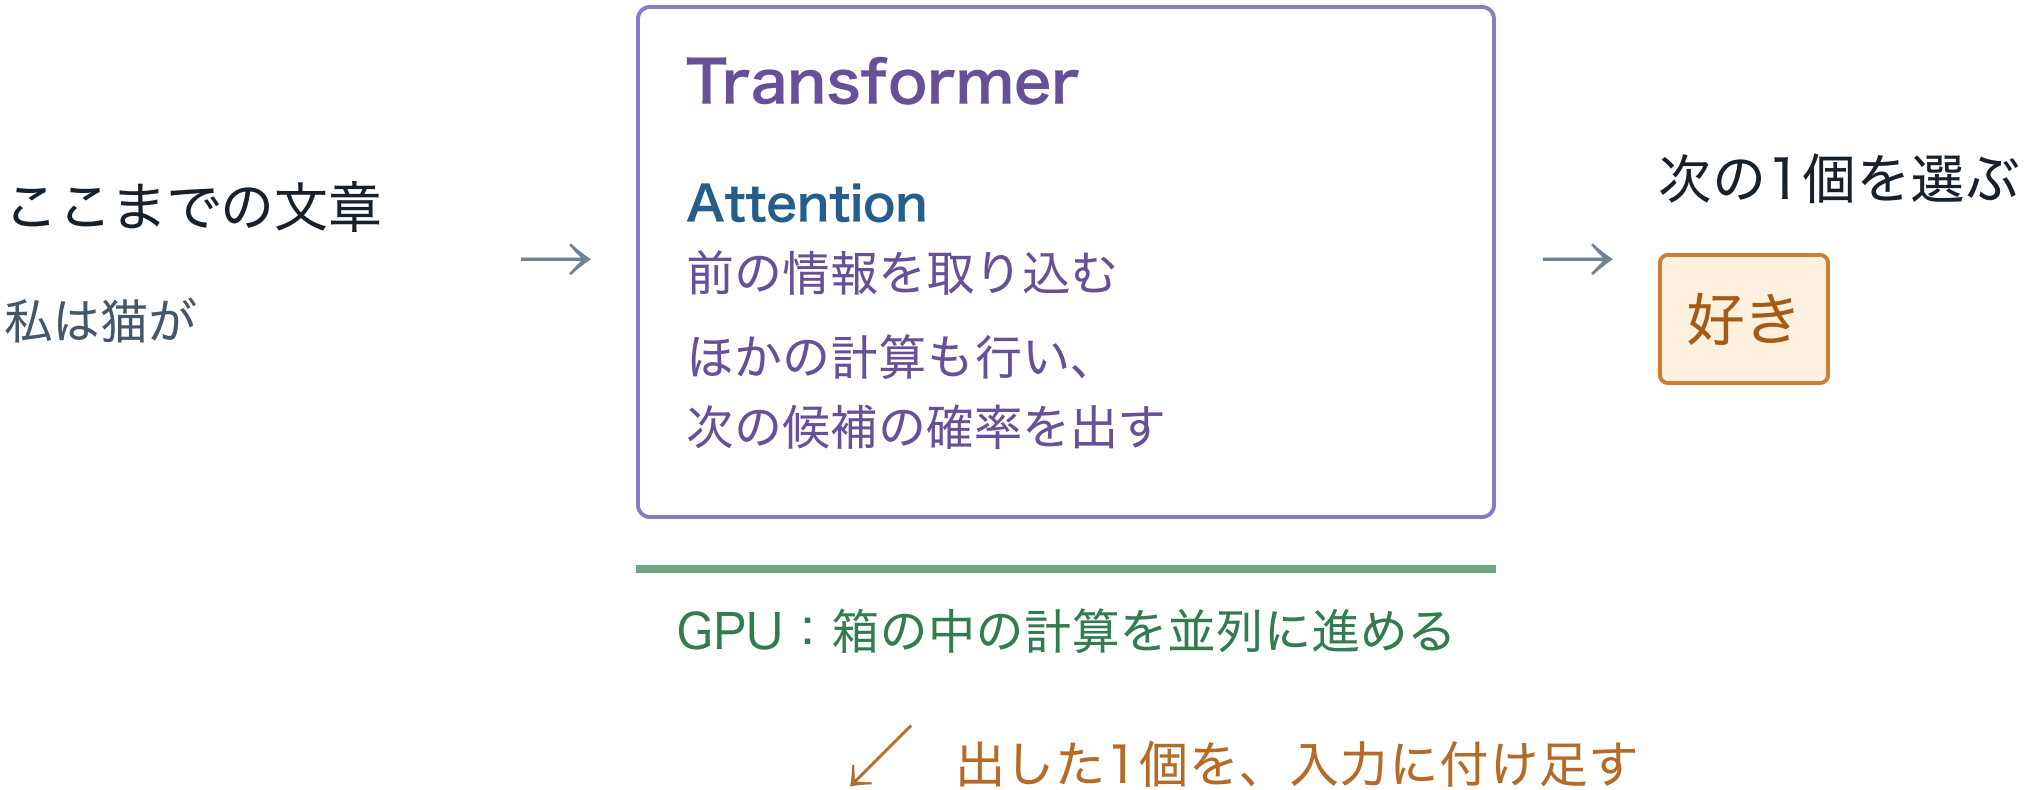
箱の中：計算を並列に

言葉の生成：前の出力を待つ

通常の自己回帰生成を説明。学習時は、未来の正解を隠して複数位置の予測をまとめて計算できる。

最初の図に、役割を重ねる

文脈から次を予測する計算を、GPUで速く進めます。



CPUとGPUは、得意な仕事を分担できます。

本編 boku_nano_presentation.md の9ページ目と対応。図の出力は説明用の例。

出典と、図の読み方

研究の内容と、仕組みを伝えるための自作例を分けています。

1948	Shannon: A Mathematical Theory of Communication	§3：27記号、文字の頻度とつながりを使う英語の近似
1951	Shannon: Prediction and Entropy of Printed English	§3：人に次の文字を予測してもらう実験
2017	Vaswani et al.: Attention Is All You Need	§3.2・§4：Attentionの計算と並列性
GPU	NVIDIA: Matrix Multiplication Background	§2：演算量・メモリ制約・GPUでの行列計算
CPU	NVIDIA: CPUとGPUの設計	仕事の選び方 ／ Intel：分岐予測などの仕組み

氏名：MIT公式略歴で Claude Elwood Shannon を確認。
文字列・確率・Attentionの重み・大会は、説明用に作成。